

基于多层感知机的多层介质薄膜光谱预测与辅助设计

MLP-Based Spectral Prediction and Data-Driven Design of Multilayer Dielectric Thin Films

姓名: _____ 学号: 2020276134

$\lambda_{\text{target}} = 480 \text{ nm}$ seed = 276134 design_seed = 276135

摘要

本文研究一个小型多层感知机 (MLP) 能否作为四层介质薄膜光学响应的快速代理模型, 并辅助设计在个人目标波长 480 nm 处反射率最大的膜系。我们用传输矩阵法 (TMM) 对固定膜系 Air/H/L/H/L/Glass 的 5,000 组随机膜厚组合计算了反射光谱 ($n_H = 2.30$, $n_L = 1.45$, $n_S = 1.52$, 每层 40 - 180 nm, 41 个波长点覆盖 400 - 800 nm), 并用随机种子 276134 一次性划分为 4,000/500/500 的训练、验证与测试集。MLP (结构 4-128-128-64-41, 28,073 个可训练参数, MSE 损失, Adam 优化器) 由四个膜厚直接预测整条光谱, 测试集 RMSE 为 0.0089 (测试 MSE $7.93e-05$), 约为数据集平均反射率的 3.0%; 在 480 nm 处的平均绝对误差仅 0.0078。训练样本由 500 增至 4000 时, 测试 RMSE 由 0.0289 降至 0.0089, 但最后一次翻倍仅带来 41% 的 MSE 下降, 边际收益明显递减。用 design_seed 276135 生成 10,000 组候选并用代理模型筛选, 耗时 0.01 s, 而 TMM 需 0.1 s (加速 $\times 13.7$); 代理模型选出的最优设计经 TMM 验证在 480 nm 处反射率为 0.6566。因此 MLP 可作为大规模筛选的高效代理, 但其排序必须由 TMM 复核。

关键词: 光学薄膜; 传输矩阵法; 多层感知机; 代理模型; AI for Science

1. 引言

多层介质薄膜是光学工程中历史悠久且应用最广的元件之一。其光学响应来自各层界面处部分反射光的干涉, 因此反射光谱只由三类设计参数控制: 层数、各层材料 (折射率) 与各层厚度 [1, 2]。由于膜层厚度与波长可比, 厚度的微小变化会显著改变光在该层中积累的相位, 从而改变干涉条纹的位置与深度。即便对于本文研究的最简四层膜系, 膜厚到光谱的映射也呈现强非线性, 且条纹疏密随总光学厚度增加而增大。

描述该膜系的标准物理模型是传输矩阵法 (TMM) [1, 3]: 每层用一个 2×2 特征矩阵表示, 矩阵元取决于该层的光学相位厚度; 各层矩阵按顺序相乘得到膜系的输入导纳, 进而解析地给出振幅反射系数与反射率。对本研究采用的理想化模型 (平面波、正入射、无吸收、无色散) 而言, TMM 是精确的, 且单个设计的计算量很小。困难出现在需要评估极大量设计时, 例如在确定设计方案前要对 10,000 组候选排序: 计算量随候选数线性增长, 并主导整个优化流程。

机器学习代理模型为这一矛盾提供了出路。以 TMM 数据训练的神经网络可以直接从样本中学习“设计参数 $\rightarrow$ 光学响应”的映射 [4], 训练完成后, 单个设计只需一次前向传播即可评估, 比数值仿真快若干数量级。此类代理模型已被广泛用于光学多层结构的逆向设计, 既可作为向量化回归器, 也可作为生成模型 [4 - 7]。代价是代理模型只是近似: 它可能把性能接近的候选排错, 且精度取决于可用训练数据量。本作业的推荐阅读文献 [4] 正是从传统优化到深度学习的系统综述。

本文针对一个刻意简化的体系提出三个问题: 该体系为四层 Air/H/L/H/L/Glass 膜系, 折射率固定, 仅四个膜厚为自由参数。(Q1) MLP 能否准确预测该膜系的反射光谱? (Q2) 训练样本数增加时预测误差如何变化? (Q3) MLP 能否作为代理模型辅助对大规模候选库快速筛选, 从而找到在个人目标波长处反射率较高的设计? 三个问题都在同一套固定数据集、同一个固定的训练/验证/测试划分以及显式记录的随机种子下回答, 因此下文每一个数字都可复现。图 1 给出了总体流程。




图 1. AI4S 薄膜研究总体流程。数据集由 seed = 276134 生成; 筛选候选库使用 design_seed = 276135, 最终 Top-5 设计始终由 TMM 复核。

2. 材料与方法

2.1 光学模型与传输矩阵法

研究对象为四层膜系 Air / H / L / H / L / Glass，正入射平面波照明。各层无吸收、无色散，折射率分别为 $n_H = 2.30$ （第 1、3 层）与 $n_L = 1.45$ （第 2、4 层）；基底为玻璃 $n_s = 1.52$ ，入射介质为空气 $n_0 = 1.00$ 。膜厚 d_i 与真空波长 λ 均以纳米为单位。

第 i 层的光学相位厚度为 $\delta_i = 2\pi n_i d_i / \lambda$ 。正入射下的光学导纳 $\eta_i = n_i$ ，该层的特征矩阵为 $M_i = \begin{bmatrix} \cos \delta_i & i \sin \delta_i / \eta_i \\ i \eta_i \sin \delta_i & \cos \delta_i \end{bmatrix}$ 。膜系矩阵为有序乘积 $M = M_1 M_2 M_3 M_4$ （光由第 1 层向基底传播），输入导纳 $Y = (M_{21} + M_{22} \eta_s) / (M_{11} + M_{12} \eta_s)$ ，振幅反射系数与反射率分别为 $r = (\eta_0 - Y) / (\eta_0 + Y)$ 与 $R = |r|^2$ 。实现见 `src/tmm.py`，可对整个设计批次与全部波长一次性求解。`tests/test_tmm.py` 包含六项物理自检：零厚度膜系退化为空气/玻璃单界面菲涅耳反射率 0.0426；单层四分之一波长层的反射率与解析值 $R = ((\eta_0 - n^2/n_s)/(\eta_0 + n^2/n_s))^2$ 一致；批量计算与逐条计算在 $1e-13$ 内一致；400 组随机膜系在 41 个波长上均满足 $0 \leq R \leq 1$ 。由于模型无损耗， R 直接作为待学习的物理量。




图 2. 物理模型与基于 TMM 的“膜厚—光谱”数据生成。(A) Air/H/L/H/L/Glass 膜系；(B) 20000 个采样膜厚的分布；(C) 5000 条 TMM 计算光谱中的四条示例。

2.2 个性化参数：目标波长与随机种子

按作业要求，个性化参数由学号 2020276134 确定。学号后两位 $N = 34$ ，故目标波长为 $\lambda_{\text{target}} = 450 + 10 \times (N \bmod 31) = 480$ nm，对应 41 个波长采样点中的第 8 个。随机种子取学号后六位整数 `seed = 276134`，它控制数据集生成、定义训练/验证/测试划分的那一次随机排列，以及 MLP 权重的初始化。设计阶段使用 `design_seed = seed + 1 = 276135`，以保证候选膜系不会与训练数据重复。所有脚本在启动时显式设置 `random`、`numpy` 与 `torch` 三个随机种子。

生成的数据集指纹记录于 `results/dataset_fingerprint.json`: `sha256(thickness) = b01a114170b65a8f...`, `sha256(spectra) = 55bda16158cadb23...`, `sha256(split) = 9898a922634fd93b...`, $R \in [0.0000, 0.6582]$ ，平均 $R = 0.3017$ 。重新运行 `src/data.py` 可复现这些摘要值，本稿的数值一致性即以此校验。

2.3 数据集生成

用种子 276134 为四层各抽取 5,000 组均匀分布于 $[40, 180]$ nm 的膜厚组合，并用 TMM 在 400–800 nm、步长 10 nm 的 41 个波长点上计算反射率。紧随膜厚抽取之后，同一随机数生成器给出 5000 个样本的一次随机排列，据此形成固定的 4,000 训练 / 500 验证 / 500 测试划分，排序后的索引随数据一并保存。该划分用于本文所有实验，且不再重新打乱。

2.4 MLP 代理模型

代理模型为全连接网络：输入维度 4（四个膜厚，用固定常数 110 nm 与 70 nm 归一化到 $[1, 1]$ ，使输入尺度不依赖具体训练子集），隐藏层分别为 128、128、64 并使用 ReLU 激活，输出 41 维，即作业建议的 4-128-128-64-41 结构，共 28,073 个可训练参数。由于无损耗膜系必然满足 $0 \leq R \leq 1$ ，输出层采用 sigmoid 激活，使网络在结构上即为物理有界。权重按 He 初始化从带种子的 `torch` 生成器中抽取。损失为预测反射率与 TMM 反射率之间的均方误差；训练使用 Adam，学习率恒为 0.001，批大小 64，共 2000 轮，小批量打乱同样由种子 276134 的生成器给出。保留验证 MSE 最低那一轮的权重。完整模型在单核 CPU 上训练耗时 83 s (PyTorch 2.14.0+cpu, 1 线程)。




图 3. MLP 代理模型结构（4-128-128-64-41，28,073 个参数），由四个膜厚映射到 41 点反射光谱。

2.5 训练数据量实验

为单独考察数据量的影响，依次取固定 4000 组训练池中的前 500、1000、2000 与 4000 组训练模型。由于训练池顺序本身即为那次固定的随机排列，较小的训练集是较大训练集的嵌套子集。验证集与测试集始终不变，且种子、网络结构、优化器、学习率、批大小与训练轮数在四次运行中完全一致，因此测试误差的任何差异只来自训练样本数。

2.6 MLP 辅助薄膜筛选

用训练好的代理模型筛选 10,000 组以 `design_seed = 276135` 从同一均匀膜厚分布生成的新候选膜系。先用 MLP 预测全部候选光谱，按 480 nm 处预测反射率排序，取前十名用 TMM 重新计算；最终排名即这十个候选的 TMM 排名，表 1 给出其中最好的五个。这里需要区分两个量：设计目标量（ λ^{target} 处的 R ）与候选的预测/真实光谱一致性。只有后者决定代理模型的排序是否可信。

3. 结果

3.1 MLP 训练与光谱预测




图 4. MLP 代理模型的训练损失与验证损失。

图 4 给出两条损失曲线。训练 MSE 由首轮 的 2.38×10^{-3} 降至 2000 轮结束时的 5.94×10^{-5} ，验证 MSE 在第 1918 轮达到最小值 7.83×10^{-5} ，其后始终紧贴训练曲线。两条曲线之间没有可见间隙，说明网络并未对 4000 组训练样本过拟合，剩余误差是代理模型的逼近误差而非记忆误差。所保留的模型在验证集上 MSE 为 7.83×10^{-5} （RMSE 0.0089），在 500 组测试样本上的 MSE 为 7.93×10^{-5} ，即 RMSE = 0.0089、MAE = 0.0065，全部样本与全部 41 个波长上的最大绝对偏差为 0.0712。相对数据集平均反射率 0.3017，测试 RMSE 为 3.0 %。在个人目标波长 480 nm 处，平均绝对误差为 0.0078，MSE 为 9.99×10^{-5} ，略优于全谱平均。

图 5 给出三个代表性测试样本。对这三个样本，MLP 均复现了干涉条纹的位置与深度；其单样本 MSE 分别为 5.6×10^{-5} 、 6.8×10^{-5} 、 8.4×10^{-5} ，接近中位数单样本 MSE 6.80×10^{-5} 。光谱平滑处吻合最好，而两个相近膜厚组合产生陡峭且密集条纹处吻合最差——这恰恰是膜厚微小变化就能使条纹移动一个 10 nm 采样间隔的情形。

TMM 与 MLP 反射光谱对比 (代表性测试样本)




图 5. 代表性测试样本上 TMM 计算光谱与 MLP 预测光谱的对比。三个设计的预测误差接近中位数。

3.2 训练数据量的影响

	验证 MSE	测试 MSE	测试 RMSE	测试 MAE	最优轮次	耗时 (s)
	8.91×10^{-4}	8.33×10^{-4}	0.0289	0.0203	1837	11
	3.37×10^{-4}	2.87×10^{-4}	0.0169	0.0121	1971	21
	1.55×10^{-4}	1.35×10^{-4}	0.0116	0.0083	1938	41
	7.83×10^{-5}	7.93×10^{-5}	0.0089	0.0065	1918	84

表 2. 训练样本数对预测误差的影响 (测试集固定为 500 组)。




图 6. 训练样本数对测试误差的影响。

表 2 与图 6 汇总了四次运行。测试 RMSE 从 500 组时的 0.0289 单调下降到 4000 组时的 0.0089, MSE 总降幅为 90 %。但每再翻一倍带来的收益持续减小: 训练池由 500 增至 1000 组使测试 MSE 下降 66 %, 由 1000 增至 2000 组下降 53 %, 而由 2000 增至 4000 组仅下降 41 %。以 RMSE 比值表示, 三次翻倍分别把误差乘以 0.59、0.68 与 0.77。在所有训练规模下, 验证误差与测试误差之比不超过 1.01 倍, 说明固定的验证集是测试集的可靠代理。换言之, 模型在仅 500 组样本时已受数据量限制, 而增加数据的收益衰减很快; 若要充分利用 4000 组样本, 需要更大的模型或更好的输入表示。

3.3 MLP 辅助薄膜设计

筛选 10,000 组候选时, 代理模型耗时 0.01 s, 同一机器同一批次下 TMM 耗时 0.1 s, 加速 $\times 13.7$ 。在整个候选池上, 代理模型复现 TMM 光谱的 MSE 为 8.27×10^{-5} (MAE 0.0066); 在目标波长处平均绝对误差为 0.0079, 最大单点误差 0.0867。10000 组候选在 480 nm 处的真实 (TMM) 反射率范围为 0.0001 - 0.6566, 均值 0.2994, 99.9 分位数为 0.6492, 可见下文选出的设计位于分布尾部。

图 7A 给出五个入选候选的光谱及经 TMM 复核后的选定设计 (代理模型对全部 10000 组候选排序, 取前十名用 TMM 重算; 图 7B 给出这十个候选的 MLP 排序与 TMM 验证结果的关系)。




图 7. 选定设计的 MLP 预测光谱与 TMM 验证光谱。(A) 选定设计与五个入选候选的光谱，并标出个人目标波长；(B) 十个候选的 MLP 排序与 TMM 验证结果对比。

d1 (nm)	d2 (nm)	d3 (nm)	d4 (nm)	MLP R_{target}	TMM R_{target}
51.9	86.8	158.1	77.7	0.6636	0.6566
161.5	84.9	49.7	76.1	0.6674	0.6527
52.3	87.6	149.0	96.5	0.6626	0.6522
155.2	95.3	51.3	86.2	0.6610	0.6490
159.3	92.8	149.1	78.1	0.6590	0.6473

表 1. 由 MLP 选出并经 TMM 验证的前五个候选膜系设计 ($\lambda_{\text{target}} = 480$ nm)。

最优设计的膜厚为 [51.9, 86.8, 158.1, 77.7] nm，TMM 验证其在 480 nm 处反射率为 0.6566，而代理模型预测为 0.6636，绝对误差仅 0.0069。该设计优于候选池的 99.9 分位数 (0.6492)，也超过候选池平均反射率 0.2994 的两倍。不过，重新排序确实改变了次序：代理模型排在第一位的候选 (预测 $R = 0.6674$) 经 TMM 验证后落到第 2 名，真实反射率为 0.6527；而经 TMM 确认的第一名当初被 MLP 排在第 2 位。两者预测反射率仅相差 0.0038，与代理模型在目标波长处的自身误差 (0.0079) 同一量级，可见排序反转正是残余预测误差的直接后果。表 1 中的五个设计都进入了代理模型的 Top-10，但若直接采用 MLP 的原始次序，只有 5 个会被选中；校正后的表 1 必须由 TMM 产生。

3.4 典型失败案例




图 8. 一个预测误差相对较大的典型案例 (500 个测试样本中排名第 1，单样本 MSE $5.33\text{e-}04$)。

图 8 给出 500 个测试样本中最差的一个。其单样本 MSE 为 $5.33\text{e-}04$ (RMSE 0.0231)，单波长最大偏差达 0.0619，约为平均测试 RMSE 的 3 倍，对应膜厚为 [103.2, 179.8, 178.0, 142.4] nm。图 8B 显示两个特征。其一，误差在相邻条纹间变号，而非随反射率量级同步增大，这是干涉条纹位置存在小误差、而非整体水平错误的典型特征：预测曲线被轻微拉伸，于是在某些波长偏高、在相邻波长偏低。条纹整体位移正是光学厚度 $n_i d_i$ 被轻微误估的结果。其二，误差集中在光谱短波半区，那里条纹最陡：在 10 nm 采样间隔内反射率可变化 0.05 以上，网络必须把极值定位到优于一个采样点的精度。图 8C 把该样本放回误差分布中：中位数单样本 MSE 为 $6.80\text{e-}05$ ，95 分位数为 $1.68\text{e-}04$ ，最差样本约为中位数的 8 倍。

倍，仍在同一数量级内，说明代理模型是平缓退化而非灾难性失效。更密的波长采样可以消除其中一部分误差。

4. 讨论

关于第一个研究问题，代理模型对未见设计的 TMM 光谱复现精度为测试 RMSE 0.0089，约为数据集平均反射率的 3.0%，仅为数据集最大反射率的 1.4%。图 5 表明剩余误差主要来自干涉条纹的位置与陡峭程度，而非整体水平偏差：误差在相邻条纹间变号（见 3.4 节），这正是光学厚度 $n_i d_i$ 被轻微误估的表现。由于反向映射“膜厚→光谱”是多对一的（不同膜系可给出十分相似的光谱），其中一部分残差对任何确定性回归器都不可消除，若要显著降低它，需要集成模型或概率化输出。

关于第二个研究问题，更多数据有帮助，但收益强烈递减（图 6）：500 至 1000 组之间误差下降很快，此后趋于平缓，最后一次把训练集翻倍只换来 41% 的 MSE 下降。这是光滑函数逼近器的典型行为：500 组样本不足以稠密覆盖四维膜厚空间，而超过数千组后，误差主要由网络结构与优化过程而非数据量决定。这也意味着对本问题而言，与其再生成数万条 TMM 光谱，不如先改进模型或输入表示（例如加入 $n_i d_i$ 这类有物理意义的特征）。

关于第三个研究问题，代理模型在筛选任务中确实有用。对 10,000 组候选排序，使用 MLP 比使用 TMM 便宜 $\times 13.7$ ，且经 TMM 验证存活下来的设计达到 0.6566，高于候选池的 99.9 分位数。因此代理模型承担了速度关键的环节（把庞大候选库缩减为少数入围者），而把精度关键的环节交给物理模型。图 7B 给出了定量依据：MLP 对十个入围候选的排序与 TMM 几乎但不完全相同——它自己最看好的候选被降到第二名——且它对最优设计 R_{target} 的预测与验证值相差 0.0069。若仅凭代理模型给出设计，结果不仅会偏乐观，还可能在几个性能接近的候选中选错获胜者，因此表 1 的最终数值必须来自 TMM。这种“代理模型搜索、物理模型验证”的分工，与深度学习辅助逆向设计文献[4–7]中的做法一致。

本研究存在明显局限。光学模型刻意简化：无色散、无吸收、仅正入射，且折射率与层数固定，因此代理模型只学习了一个四维映射。5,000 条 TMM 光谱的数据集均匀覆盖膜厚立方体，而真实设计问题往往集中在其中很小的区域，那里局部数据密度——以及精度——会更低。图 8 的失败案例正说明了后果：代理模型恰好在滤波器最关心的陡峭光谱特征处最不可靠。此外，MLP 只用了单一随机种子与单一结构训练，所报告的误差反映的是数据划分的差异，而非训练过程的波动；要区分二者需要用不同初始化重复实验。

5. 结论

本文以折射率固定的四层 Air/H/L/H/L/Glass 介质膜系为对象，检验小型 MLP 能否作为传输矩阵法的代理模型。（Q1）可以：4-128-128-64-41 网络（28,073 个参数）对未见设计 41 点反射光谱预测精度为测试 RMSE 0.0089（为平均反射率的 3.0%），在个人目标波长 480 nm 处平均绝对误差仅 0.0078。（Q2）增加训练数据有帮助但收益急剧递减：测试 RMSE 由 500 组时的 0.0289 降至 4000 组时的 0.0089，而最后一次翻倍仅使 MSE 下降 41%。（Q3）可以，但必须验证：用代理模型筛选 10,000 组候选比 TMM 快 $\times 13.7$ ，所选设计经 TMM 验证在 480 nm 处反射率为 0.6566，高于候选池的 99.9 分位数，不过最终排名始终需要由物理模型重新计算。

数据与代码可用性

本文数据由本研究开发的 TMM 代码生成。全部源代码、模型训练脚本、薄膜筛选脚本、环境依赖以及复现主要结果的说明见：
<https://github.com/Jfzz-KK/123435>
 仓库 README 中明确写出学号个性化参数 $\lambda_{\text{target}} = 480 \text{ nm}$ 、seed = 276134 与 design_seed = 276135，并给出重建数据集、训练代理模型、复现图 1–8 与表 1 的命令，以及生成数组的 sha256 指纹。

参考文献

- [1] Macleod, H. A. Thin-Film Optical Filters, 4th ed. CRC Press, Boca Raton, 2010. ISBN 978-1-4200-7302-7.
- [2] Born, M., and Wolf, E. Principles of Optics, 7th ed. Cambridge University Press, Cambridge, 1999. ISBN 978-0-521-64222-4.
- [3] Byrnes, S. J. Multilayer optical calculations. arXiv:1603.02720, 2016. <https://doi.org/10.48550/arXiv.1603.02720>
- [4] Ma, T., Ma, M., and Guo, L. J. Optical multilayer thin film structure inverse design: From optimization to deep learning. iScience 2025, 28, 112222. <https://doi.org/10.1016/j.isci.2025.112222>
- [5] Liu, D., Tan, Y., Khoram, E., and Yu, Z. Training deep neural networks for the inverse design of nanophotonic structures. ACS Photonics 2018, 5, 1365–1369. <https://doi.org/10.1021/acsphotonics.7b01377>
- [6] Peurifoy, J., Shen, Y., Jing, L., Yang, Y., Cano-Renteria, F., DeLacy, B. G., Joannopoulos, J. D., Tegmark, M., and Soljacic, M. Nanophotonic particle simulation and inverse design using artificial neural networks. Science Advances 2018, 4, eaar4206. <https://doi.org/10.1126/sciadv.aar4206>

- [7] Ma, T., and Guo, L. J. OptoGPT-based design of multilayer thin film structures. *Optics Express* 2024, 32, 31703–31715. <https://doi.org/10.1364/OE.529375>
- [8] Tikhonravov, A. V., Trubetskov, M. K., and DeBell, G. W. Application of the needle optimization technique to the design of optical coatings. *Applied Optics* 1996, 35, 5493–5508. <https://doi.org/10.1364/AO.35.005493>
- [9] Martin, S., Rivory, J., and Schoenauer, M. Synthesis of optical multilayer systems using genetic algorithms. *Applied Optics* 1995, 34, 2247–2254. <https://doi.org/10.1364/AO.34.002247>
- [10] Kingma, D. P., and Ba, J. Adam: A method for stochastic optimization. In 3rd International Conference on Learning Representations (ICLR), San Diego, 2015. [arXiv:1412.6980](https://arxiv.org/abs/1412.6980)
- [11] He, K., Zhang, X., Ren, S., and Sun, J. Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification. In Proceedings of the IEEE International Conference on Computer Vision (ICCV), Santiago, 2015, pp. 1026–1034. <https://doi.org/10.1109/ICCV.2015.123>
- [12] Virtanen, P., Gommers, R., Oliphant, T. E., et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods* 2020, 17, 261–272. <https://doi.org/10.1038/s41592-019-0686-2>